

RAG 评测与可重复实验设计

DOC_ID: DOC-EVAL-001

说明：本文档为 RAGLab 项目生成的教学用合成语料，用于分块、检索、重排、引用和评测实验。它不是 LangChain/LangGraph 官方文档，也不应被当作 API 版本说明。文中的稳定标识（DOC_ID、SECTION_ID）用于构建可重复的检索评测集。

1. 为什么不能只看最终回答

SECTION_ID: EVAL-LAYER-01

RAG 的失败可能发生在检索或生成阶段。只评价最终答案，无法区分“没有找到正确文档”和“找到文档但模型没有正确使用”。

因此至少拆成两层：

```
Retrieval Evaluation
+
Generation Evaluation
```

2. Golden Dataset

SECTION_ID: EVAL-DATA-01

每条评测样本至少应包含：问题、参考答案、相关文档 ID、相关章节 ID、类别和难度。对于不可回答问题，应显式标记 `answerable=false`。

```
{
  "question": "Checkpoint 和 Store 的区别是什么？",
  "expected_answer": "...",
  "relevant_doc_ids": ["DOC-LG-001"],
  "relevant_section_ids": ["LG-CP-01", "LG-STORE-01"],
  "answerable": true
}
```

Golden Dataset 的价值取决于标注质量，而不是样本数量。第一版 30 到 50 条高质量问题通常比 500 条自动生成但未经核验的问题更有价值。

3. Hit@K、Recall@K 与 MRR

SECTION_ID: EVAL-RET-01

Hit@K 判断前 K 条结果中是否至少包含一个相关文档。Recall@K 衡量所有相关文档中被找回的比例。MRR 关注第一个相关结果的排名。

例如相关章节有 2 个，Top-5 找回其中 1 个，则 Recall@5 为 0.5；若第一个相关结果排在第 2 位，则该样本的 Reciprocal Rank 为 0.5。

4. nDCG 与多级相关性

SECTION_ID: EVAL - NDCG - 01

当文档相关性不是简单的相关/不相关，而是“核心证据、辅助证据、背景材料”时，可以使用多级相关性和 nDCG。nDCG 同时考虑相关程度和排名位置。

5. 回答正确性与忠实性

SECTION_ID: EVAL - GEN - 01

回答正确性关注答案是否满足问题和参考答案；忠实性关注回答中的事实是否得到检索上下文支持。二者可能不一致：

- 回答正确但没有依据当前文档，可能是模型记忆；
- 回答忠实但检索文档本身不完整，最终答案仍可能不正确。

6. 引用评测

SECTION_ID: EVAL - CITE - 01

引用评测至少包含：

1. 引用格式是否可解析；
2. 引用的 doc_id 和 section_id 是否存在；
3. 被引用片段是否支持对应结论；
4. 关键结论是否都有引用。

仅返回一个“来源列表”并不能证明每句话有依据。

7. 成本与延迟

SECTION_ID: EVAL - COST - 01

检索效果提升不能脱离成本评估。应记录：Embedding 时间、检索时间、重排时间、模型首 Token 延迟、总耗时、输入 Token 和输出 Token。

Multi-Query、LLM Rerank 和多轮检索可能提升准确率，但也会显著增加费用。实验报告应同时展示效果和成本。

8. 控制变量与版本记录

SECTION_ID: EVAL - EXP - 01

每次实验只改变少量变量，并保存完整配置：语料版本、分块器、Embedding 模型、索引版本、Retriever、Top-K、Reranker、Prompt、生成模型和温度。

建议给每次实验一个可读名称：

```
recursive_600_dense_k5  
markdown_600_hybrid_rerank_k4  
parent_child_multiquery_v1
```

没有版本记录的“效果变好了”无法复现，也无法写进可信的项目报告。